МТУСИ
МОСКОВСКИЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ СВЯЗИ И ИНФОРМАТИКИ

Разработка системы интеллектуальной классификации и пакетной сортировки документов на языке Python с low-code интерфейсом

Студент: Медведев Илья

Группа: не указана

Научный руководитель: данные уточняются

Практическая задача и актуальность

Смешанные архивы

Организации получают документы текстом, сканами и пакетами файлов.

Ручная сортировка

Разбор массива документов занимает время и плохо масштабируется.

ML-подход

Тип документа можно определять по тексту и по структуре макета.

Low-code UI

Gradio дает быстрый прикладной интерфейс без отдельного frontend.

Цель работы

Разработать локальное приложение, которое классифицирует документы и автоматически сортирует ZIP-архив по типам: договор, счет, приказ, служебная записка, отчет.

Результат ВКР - не абстрактный классификатор, а прикладной сервис первичной маршрутизации документов.

Поддерживаемые сценарии

1. Текст документа

Ввод текста и мгновенное определение типа документа.

2. Скан документа

Загрузка изображения и классификация по макету страницы.

3. ZIP-архив

Пакетная сортировка массива файлов и выдача нового архива.

Классы документов

Договор
Счет
Приказ
Служебная записка
Отчет

Ключевое расширение проекта - пакетная сортировка архива, добавляющая практическую ценность приложению.

Архитектура решения

Интерфейс

Gradio собирает три прикладных сценария в одном окне.

Сервисный контур

FastAPI и сервисный слой управляют классификацией и логированием.

Хранилище и архивы

SQLite хранит историю, архивный модуль формирует CSV и ZIP-результат.

Архитектура ориентирована на переносимость и локальный запуск без внешних сервисов.

Программная реализация

Что реализовано

текстовая модель TF-IDF + Logistic Regression
визуальная модель Random Forest
пакетная сортировка ZIP-архива

Сопровождающие блоки

SQLite-журнал истории
демо-архив и отчеты
автотесты и скрипты пересборки

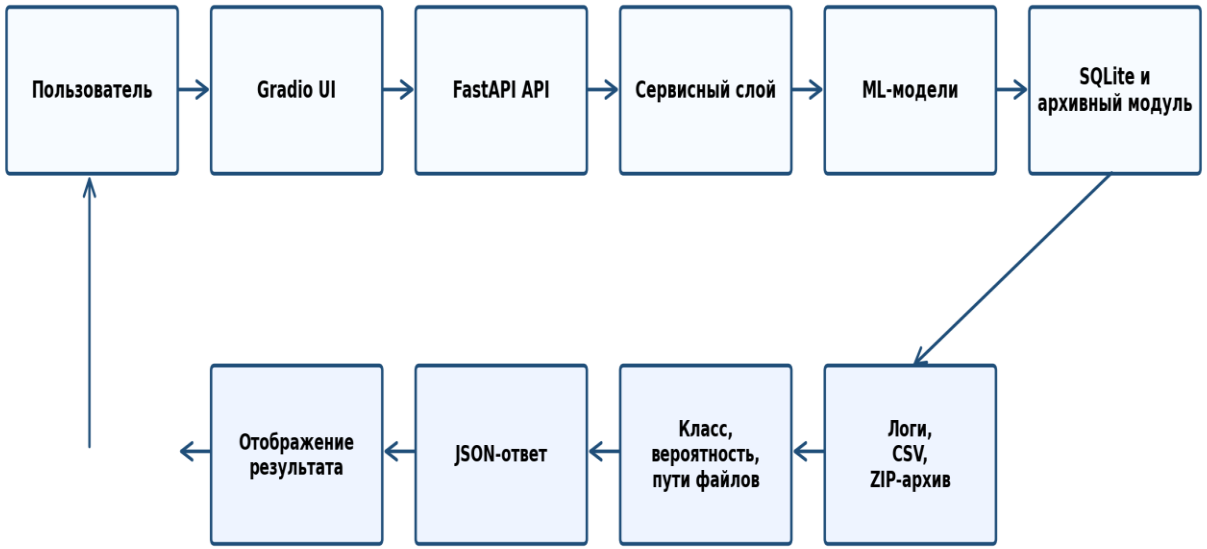

Интерфейс показывает не только прогноз, но и метрики моделей и историю пакетных прогонов.

Результаты тестирования и экспериментов

Текстовая модель

Accuracy: 1.0000

F1-score: 1.0000

Модель сканов

Accuracy: 1.0000

F1-score: 1.0000

16 автотестов, покрытие кода выше 85%, интерактивное время ответа после прогрева.

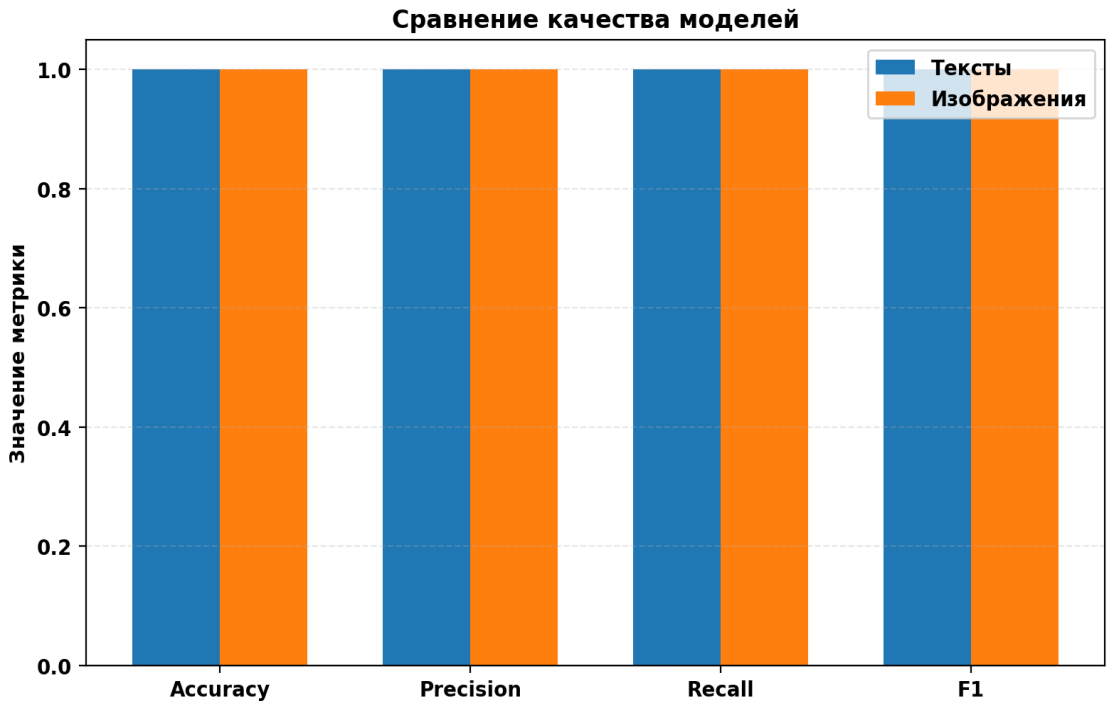

Пакетный режим формирует CSV-сводку и новый ZIP-архив с разложением по типам документов.

Практическая ценность и развитие

Практический эффект

Сервис выполняет первичную расфасовку архива документов без ручного открытия каждого файла.

Инженерная зрелость

Есть рабочее приложение, локальная БД, тесты, диаграммы, пояснительная записка и презентация.

Направления развития

Подключение реальных корпусов документов, OCR и более сложных мультимодальных моделей.

Разработанное ПО может выступать как прототип сервиса первичной маршрутизации корпоративных документов.

Аналоги и ниша решения

ABBYY FlexiCapture

Сильный OCR и захват документов

Но решение тяжелее и дороже локального стенда ВКР

Directum / ELMA / 1С

Закрывают полный ECM-контур

Но ориентированы на корпоративное внедрение

Наш проект

Локальный запуск

Пакетная сортировка архива

Прозрачный ML-контур

Ниша разрабатываемого ПО

Компактный сервис предварительной маршрутизации документов: не заменяет ECM-платформу, а решает задачу быстрой первичной сортировки и демонстрирует воспроизводимый прикладной ML-проект.

Ключевое отличие - фокус именно на локальной сортировке массива документов и простом повторяемом развертывании.

База данных и результат пакетной сортировки

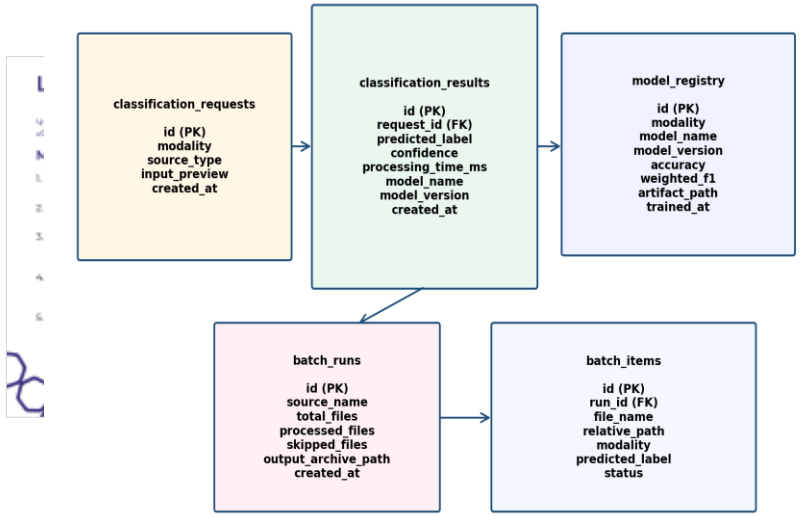

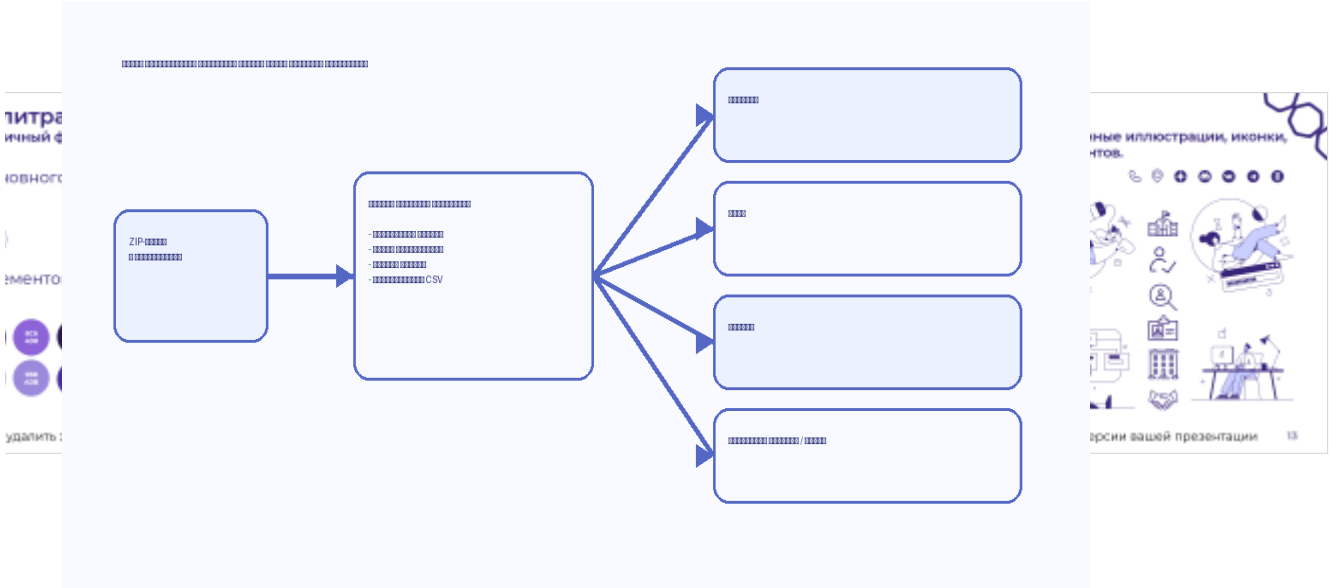

SQLite

Хранит одиночные запросы, пакетные прогоны и реестр моделей.

CSV-сводка

По каждому файлу сохраняются путь, класс и статус обработки.

Итоговый ZIP

Пользователь получает архив с папками по типам документов.

Пакетный режим связывает ML-модели, файловую систему и журналирование в единую прикладную цепочку.

Выводы и перспективы развития

Разработанное ПО решает прикладную задачу первичной маршрутизации массива документов в локальном контуре.

Подтверждено

Рабочий интерфейс объединяет текстовый, визуальный и пакетный сценарии.

Система сохраняет историю операций и выдает структурированный результат сортировки.

Качество моделей и автотесты подтверждают воспроизводимость решения.

Дальнейшее развитие

Интеграция OCR для PDF и сканов документов.

Расширение корпуса и номенклатуры типов документов.

Подключение к реальным корпоративным потокам документооборота.

Итог ВКР: получен переносимый прототип системы интеллектуальной сортировки документов на Python.