МТУСИ
МОСКОВСКИЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ СВЯЗИ И ИНФОРМАТИКИ

Разработка системы интеллектуальной классификации и пакетной сортировки документов на языке Python с low-code интерфейсом

Студент: Медведев Илья

Группа: не указана

Научный руководитель: данные уточняются

Практическая задача и актуальность

Смешанные архивы

Организации получают документы текстом, сканами и пакетами файлов.

Ручная сортировка

Разбор массива документов занимает время и плохо масштабируется.

ML-подход

Тип документа можно определять по тексту и по структуре макета.

Low-code UI

Gradio дает быстрый прикладной интерфейс без отдельного frontend.

Цель работы

Разработать локальное приложение, которое классифицирует документы и автоматически сортирует ZIP-архив по типам: договор, счет, приказ, служебная записка, отчет.

Результат ВКР - не абстрактный классификатор, а прикладной сервис первичной маршрутизации документов.

Поддерживаемые сценарии

1. Текст документа

Ввод текста и мгновенное определение типа документа.

2. Скан документа

Загрузка изображения и классификация по макету страницы.

3. ZIP-архив

Пакетная сортировка массива файлов и выдача нового архива.

Классы документов

Договор
Счет
Приказ
Служебная записка
Отчет

Ключевое расширение проекта - пакетная сортировка архива, добавляющая практическую ценность приложению.

Архитектура решения

Интерфейс

Gradio собирает три прикладных сценария в одном окне.

Сервисный контур

FastAPI и сервисный слой управляют классификацией и логированием.

Хранилище и архивы

SQLite хранит историю, архивный модуль формирует CSV и ZIP-результат.

Архитектура ориентирована на переносимость и локальный запуск без внешних сервисов.

Программная реализация

Что реализовано

текстовая модель TF-IDF + Logistic Regression
визуальная модель Random Forest
пакетная сортировка ZIP-архива

Сопровождающие блоки

SQLite-журнал истории
демо-архив и отчеты
автотесты и скрипты пересборки

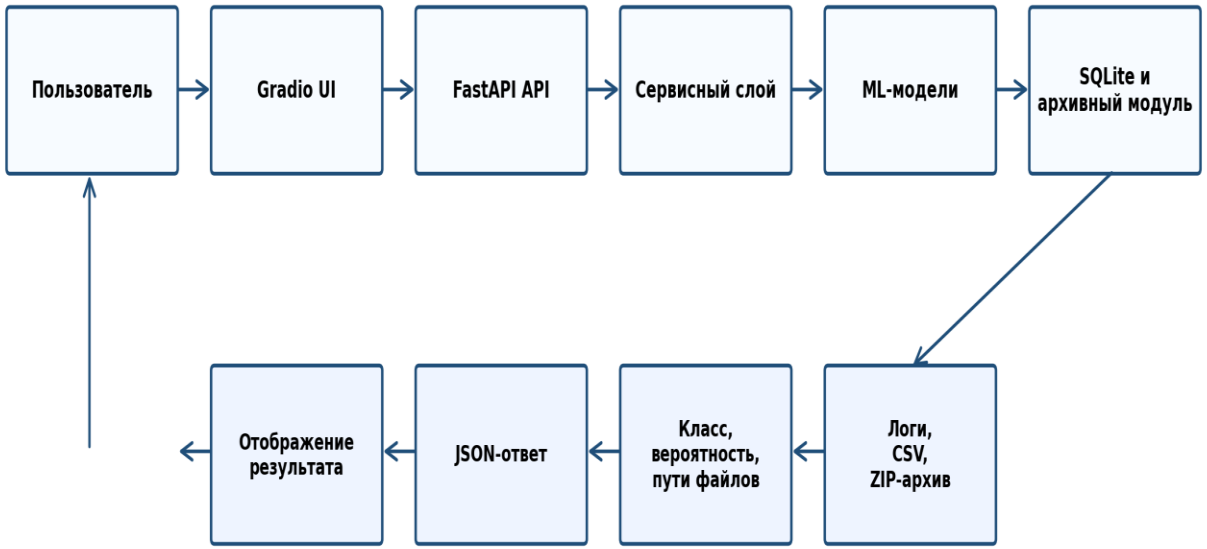

Интерфейс показывает не только прогноз, но и метрики моделей и историю пакетных прогонов.

Результаты тестирования и экспериментов

Текстовая модель

Accuracy: 1.0000

F1-score: 1.0000

Модель сканов

Accuracy: 1.0000

F1-score: 1.0000

16 автотестов, покрытие кода выше 85%, интерактивное время ответа после прогрева.

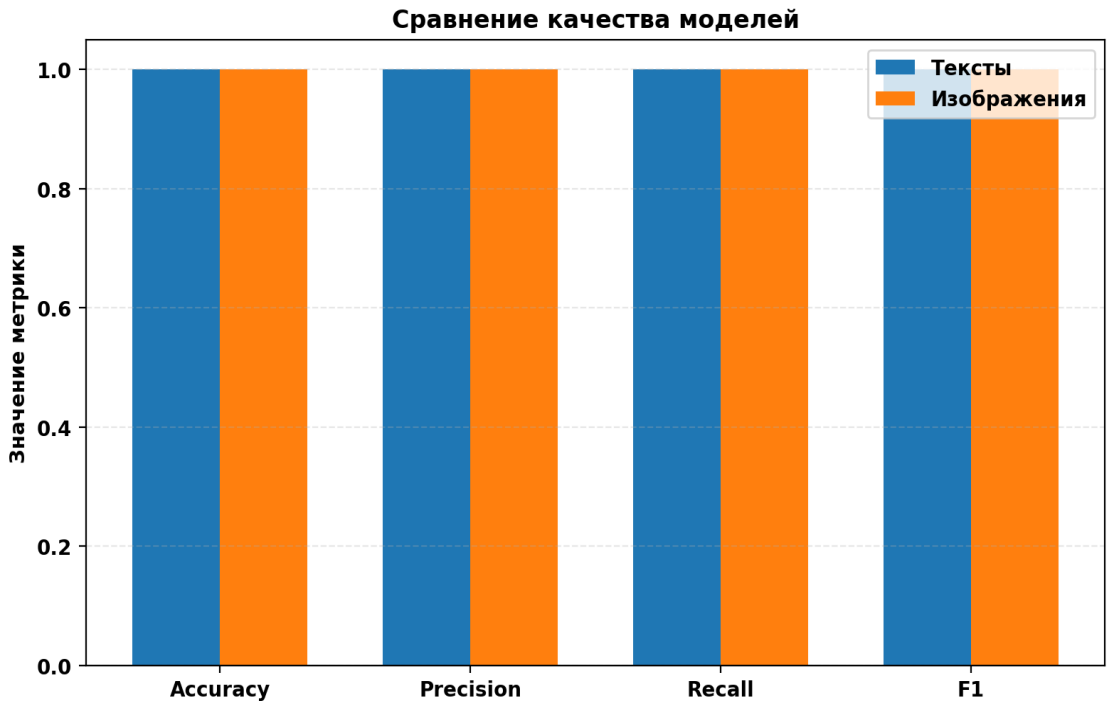

Пакетный режим формирует CSV-сводку и новый ZIP-архив с разложением по типам документов.

Практическая ценность и развитие

Практический эффект

Сервис выполняет первичную расфасовку архива документов без ручного открытия каждого файла.

Инженерная зрелость

Есть рабочее приложение, локальная БД, тесты, диаграммы, пояснительная записка и презентация.

Направления развития

Подключение реальных корпусов документов, OCR и более сложных мультимодальных моделей.

Разработанное ПО может выступать как прототип сервиса первичной маршрутизации корпоративных документов.

МТУСИ
МОСКОВСКИЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ СВЯЗИ И ИНФОРМАТИКИ

Спасибо за внимание

Студент: Медведев Илья

Группа: не указана

Научный руководитель: данные уточняются